

高雄醫學大學醫務管理暨醫療資訊學系  
資料探勘期末書面報告

# COVID疫苗接種與死亡率

指導教授:鮑永誠 教授

第七組組員:

112029007 孫裔晴(組長)

112029020 蔡欣倫

112029026 林昀蓁

112029033 賴雅秀

112029053 陳怡辰

# 中華民國 114 年 12 月

## 目錄

|                           |    |
|---------------------------|----|
| 壹、問題描述                    | 2  |
| 1.1 原始資料說明                | 2  |
| 1.2 資料型態說明                | 2  |
| 貳、問題假說                    | 3  |
| 參、資料前處理                   | 4  |
| 3.1 缺失值檢查                 | 4  |
| 3.2 異常值辨識與處理              | 4  |
| 3.3 新增資料                  | 5  |
| 1. 洲別分類                   | 5  |
| 2. 疫苗接種率                  | 6  |
| 3. 每百萬人口死亡率               | 6  |
| 4. 各國與各洲接種率及死亡率           | 6  |
| 肆、資料視覺化分析                 | 8  |
| 4.1 熱力圖分析                 | 8  |
| 4.2 各洲的平均疫苗施打率與每百萬人死亡率長條圖 | 8  |
| 4.3 全球疫苗施打率與死亡率之月平均趨勢圖    | 10 |
| 伍、實驗設計                    | 10 |
| 5.1 建立模型                  | 11 |
| 陸、模型建立與預測                 | 12 |
| 6.1 模型訓練                  | 12 |
| 6.2 模型效能評估                | 13 |
| 柒、驗證和結果                   | 14 |
| 7.1 混淆矩陣                  | 14 |
| 7.2 特徵重要度分析               | 15 |
| 7.3 預測結果分布                | 16 |
| 7.4 交叉驗證設計                | 17 |
| 7.5 小結                    | 18 |
| 捌、結論                      | 18 |
| 玖、參考文獻                    | 19 |
| 拾、問題答覆與建議                 | 20 |
| 10.1 問答與改善                | 20 |
| 10.2 老師建議                 | 21 |
| 拾壹、附錄                     | 21 |
| 11.1 工作分配                 | 21 |
| 11.2 討論紀錄                 | 22 |
| 11.3 討論參與度                | 22 |
| 11.4 修課心得                 | 23 |
| 11.5 程式碼                  | 25 |

# 壹、問題描述

## 1.1 原始資料說明

本研究所使用之原始資料為 COVID-19 各國疫苗接種與死亡情形資料集，資料來源整理自國際公開疫情資料。資料以國家、日期為觀測單位，共計 21,916 筆資料，每筆資料代表某一國家在特定日期下的疫苗接種狀況、COVID-19 新增死亡人數與人口規模。資料期間涵蓋疫苗開始施打後的疫情階段，各欄位皆為連續型數值或類別資料，有 9 個資料欄位，包含 country、iso\_code、date、total\_vaccinations、people\_vaccinated、people\_fully\_vaccinated、New\_deaths、population、ratio(表 1-1)。

| 變量名稱                    | 變量含意            | 內容                             |
|-------------------------|-----------------|--------------------------------|
| country                 | 國家名             | Afghanistan、Albania、Angola、... |
| iso_code                | 每個國家的iso代碼      | AFG、ALB、AGO、...                |
| date                    | 此數據所屬日期         | 2020/12/19~2021/10/26          |
| total_vaccinations      | 該國使用所有COVID疫苗數量 | 65~2174043000                  |
| people_vaccinated       | 至少接種一劑疫苗人數      | 64~1100842000                  |
| people_fully_vaccinated | 接種完整疫苗人數        | 1~1022207000                   |
| New_deaths              | 每日新增死亡人數        | -41~8786                       |
| population              | 2021年各國人口       | 1373~1445862313                |
| ratio                   | 疫苗施打率           | 0.000724363~120.3216808        |

表 1-1、原始資料內容統整表

## 1.2 資料型態說明

根據資料型態可區分為類別型資料 2 欄，以及連續型資料 7 欄(表 1-2)。

| 類別型資料    | 連續型資料                   |
|----------|-------------------------|
| country  | date                    |
| iso_code | total_vaccinations      |
|          | people_vaccinated       |
|          | people_fully_vaccinated |
|          | New_deaths              |
|          | population              |

|  |       |
|--|-------|
|  | ratio |
|--|-------|

表 1-2、資料型態分類表

## 貳、問題假說

近年來，COVID-19 疫苗已被廣泛施打於全球多數國家，疫苗接種人數與覆蓋率亦隨時間持續累積。然而，各國在疫苗取得速度、接種政策與民眾接受度上存在顯著差異，使得疫苗施打率在不同國家與地區間呈現不均衡的分布情形。與此同時，COVID-19 所造成的死亡情況亦因國家人口規模、醫療量能與疫情階段不同而有所差異。

在此背景下，單純以死亡人數進行比較，難以反映疫苗施打與死亡風險之間的關係，因此本研究結合疫苗接種資料、人口數與死亡相關指標，嘗試從比例與趨勢角度切入，分析疫苗施打率與 COVID-19 死亡率之關聯性。透過跨國與跨時間的資料觀察，本研究希望釐清疫苗施打率提高後，死亡率是否呈現相對下降的現象。

基於上述研究動機，本研究提出以下研究問題：

「疫苗施打率是否與 **COVID-19** 死亡率之高低及其變動趨勢存在關聯？」

並據此發展以下研究假說：

研究假說一：

在控制人口規模後，各國之疫苗施打率與 COVID-19 死亡率之間存在顯著關聯，且整體趨勢呈現疫苗施打率愈高、死亡率愈低之現象。

研究假說二：

不同洲別因疫苗施打率分布差異，其 COVID-19 死亡率亦呈現顯著差異，疫苗施打率較高之洲別，其死亡率相對較低。

研究假說三：

從時間序列觀察，疫苗施打率隨時間累積上升時，死亡率之變化趨勢呈現相對下降或趨於穩定的現象。

## 參、資料前處理

### 3.1 缺失值檢查

首先針對所有變數進行缺失值檢測，結果顯示本資料集中各欄位皆為完整資料，未發現缺失值，因此本研究不需進行缺失值補值或刪除處理。

```

=== 各欄位缺失比例(%) ===
Unnamed: 0          0.0
country             0.0
iso_code            0.0
date                0.0
total_vaccinations  0.0
people_vaccinated   0.0
people_fully_vaccinated 0.0
New_deaths          0.0
population          0.0
ratio               0.0
dtype: float64

```

圖 3-1、缺失值查詢

### 3.2 異常值辨識與處理

在異常值檢查過程中，發現部分觀測值在實務與統計意義上具有不合理情形，說明如下：

#### 1. 新增死亡人數(**New\_deaths**)出現負值

理論上新增死亡人數不應為負值，然而資料中仍出現 **New\_deaths < 0** 的情況，共計 4 筆資料(最小值為 **-41**)。此類數值可能來自各國疫情資料回溯修正或通報調整，為避免對死亡率計算與後續分析造成干擾，本研究將其視為異常值並予以移除。

#### 2. 死亡比例指標(**ratio**)出現極端高值

在比例指標(**ratio**)中，發現部分數值異常偏高，最大值達 **120.32**，顯著高於整體資料分布。經檢視後，將 **ratio > 100** 視為極端異常值，共計 89 筆資料，推測可能與人口基數過小或短期死亡數劇烈波動有關，故予以排除以避免扭曲整體分析結果。

| === 異常值預覽 (前10筆) === |            |            |            |            |
|----------------------|------------|------------|------------|------------|
|                      | country    | date       | New_deaths | ratio      |
| 1740                 | Bangladesh | 2021-10-10 | -6         | 21.673581  |
| 5577                 | Ecuador    | 2021-07-05 | -8         | 20.560622  |
| 6695                 | France     | 2021-08-27 | -6         | 73.793730  |
| 6704                 | France     | 2021-09-05 | -41        | 75.041122  |
| 7332                 | Gibraltar  | 2021-04-10 | 0          | 100.833877 |
| 7333                 | Gibraltar  | 2021-04-11 | 0          | 102.466022 |
| 7334                 | Gibraltar  | 2021-04-12 | 0          | 104.113004 |
| 7335                 | Gibraltar  | 2021-04-13 | 0          | 106.311947 |
| 7336                 | Gibraltar  | 2021-04-15 | 0          | 106.326785 |
| 7337                 | Gibraltar  | 2021-04-18 | 0          | 106.537480 |

圖 3-2、異常值查詢

### 3.3 新增資料

#### 1. 洲別分類 (Continent)

本研究資料集共涵蓋 199 個國家，為利於區域層級之比較分析，依據國家所屬地理位置，將各國分類為 6 個洲別。洲別資料係以「國家」為單位進行歸類，同一國家在不同日期的資料，皆歸屬於相同洲別。各洲之資料筆數，則為該洲內所有國家於整個資料期間所累積之觀測筆數總和。透過洲別分類，本研究得以在國家層級之外，進一步觀察不同洲系在疫苗施打情形與死亡率表現上的整體差異。

| 各洲資料筆數：       |      |
|---------------|------|
| continent     |      |
| Africa        | 1946 |
| Asia          | 5055 |
| Europe        | 8247 |
| North America | 3149 |
| Oceania       | 600  |
| South America | 2061 |
| Unknown       | 765  |

圖 3-3-1、洲別分類

## 2. 疫苗接種率(vaccination\_rate)

由於各國總人口數差異顯著，若僅以疫苗接種人數進行比較，容易產生規模偏誤，影響跨國分析結果。因此，本研究將疫苗接種狀況轉換為「疫苗接種率」，其計算方式如下：疫苗接種率(%) = 完整接種人數 ÷ 總人口數 × 100

透過人口標準化後的接種率指標，可使不同國家與洲別之疫苗覆蓋情形更具可比性。此外，若因資料重複計算或統計更新誤差，導致接種率出現超過 100% 之不合理情況，則將其上限限制為 100%，以維持資料合理性與分析穩定性。

## 3. 每百萬人口死亡率(deat\_rate\_per\_million)

考量各國人口規模差異巨大，直接比較「新增死亡人數」容易高估人口較多國家的疫情影響，因此本研究採用「每百萬人口死亡率」作為主要死亡指標，其計算方式如下：每百萬人口死亡率 = 新增死亡人數 ÷ 總人口數 × 1,000,000

此指標可將死亡人數標準化，使不同人口規模之國家在死亡風險評估上具備可比性。針對資料中可能出現之不合理極端值（如短期重複通報或資料缺失導致之異常偏高數值），本研究亦進行合理範圍限制與清洗處理，以降低對整體分析結果之干擾。

| continent | vaccination_rate | death_rate_per_million |
|-----------|------------------|------------------------|
| Asia      | 0.138550871      | 0.298901634            |
| Asia      | 0.193190089      | 0.249084695            |
| Asia      | 0.241387978      | 0.249084695            |
| Asia      | 0.276688261      | 0.47326092             |
| Asia      | 0.283306441      | 0.348718573            |
| Asia      | 0.298717311      | 0.498169389            |
| Asia      | 0.360176469      | 0.846887962            |
| Asia      | 0.369903226      | 0.672528676            |
| Asia      | 0.394408178      | 1.594142046            |

圖 3-3-2、每百萬人口死亡率

## 4. 各國與各洲接種率及死亡率(country\_avg\_vaccination\_rate、country\_avg\_death\_rate、continent\_avg\_vaccination\_rate、continent\_avg\_death\_rate)

在完成上述指標轉換後，本研究進一步整理各國及各洲之疫苗接種率與死亡率，作為後續比較分析之基礎。此做法可同時從「國家層級」與「洲別層級」檢視防疫表現差異，使分析結果不僅停留於單一日期或個別國家，而能呈現整體趨勢與區域性差異。

| 預覽 (部分欄位) |             |           |                  |                              |
|-----------|-------------|-----------|------------------|------------------------------|
|           | country     | continent | vaccination_rate | country_avg_vaccination_rate |
| 0         | Afghanistan | Asia      | 0.138551         | 0.410214                     |
| 1         | Afghanistan | Asia      | 0.193190         | 0.410214                     |
| 2         | Afghanistan | Asia      | 0.241388         | 0.410214                     |
| 3         | Afghanistan | Asia      | 0.276688         | 0.410214                     |
| 4         | Afghanistan | Asia      | 0.283306         | 0.410214                     |
| 5         | Afghanistan | Asia      | 0.298717         | 0.410214                     |
| 6         | Afghanistan | Asia      | 0.360176         | 0.410214                     |
| 7         | Afghanistan | Asia      | 0.369903         | 0.410214                     |
| 8         | Afghanistan | Asia      | 0.394408         | 0.410214                     |
| 9         | Afghanistan | Asia      | 0.441542         | 0.410214                     |

圖 3-3-3、各國接種率及死亡率

| country_avg_death_rate | continent_avg_vaccination_rate | continent_avg_death_rate |
|------------------------|--------------------------------|--------------------------|
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |
| 43.411765              | 23.244464                      | 115.610089               |

圖 3-3-4、各洲接種率及死亡率

## 5.處理不合理數值

在資料清洗與預處理階段，本研究針對疫苗接種率之邏輯正確性進行嚴格審核。依據變數定義，疫苗接種率應介於 0 與 1 之間，故將超出此合理區間之異常觀測值全數排除。本次清理程序共計移除 18,540 筆不合理資料，使樣本規模從原始的 21,823 筆精煉至處理後的 3,283 筆，以確保後續模型分析與推論之準確性。

|    | country     | iso_code | date       | vaccination_rate |
|----|-------------|----------|------------|------------------|
| 16 | Afghanistan | AFG      | 2021-08-20 | 1.072917         |
| 22 | Albania     | ALB      | 2021-05-11 | 6.324691         |
| 23 | Albania     | ALB      | 2021-05-12 | 6.545341         |
| 24 | Albania     | ALB      | 2021-05-13 | 6.720015         |
| 25 | Albania     | ALB      | 2021-05-14 | 7.131813         |
| 26 | Albania     | ALB      | 2021-05-17 | 7.770740         |
| 27 | Albania     | ALB      | 2021-05-18 | 7.967636         |
| 28 | Albania     | ALB      | 2021-05-19 | 8.164531         |
| 29 | Albania     | ALB      | 2021-05-20 | 8.277765         |
| 30 | Albania     | ALB      | 2021-05-21 | 8.348017         |

圖 3-3-5、清除不合理數值



## 肆、資料視覺化分析

### 4.1 熱力圖分析

由熱力圖(圖 4-1)可以看出疫苗接種指標、死亡率與人口規模之間的關聯程度，其數值介於 -1 至 1 之間，顏色愈接近黃色代表正相關愈強，愈接近紫色則代表負相關。從圖中觀察，資料展現出極高的一致性，尤其是各項疫苗施打指標之間呈現高度正相關，例如百分比與比例之間的完全正相關，僅反映了不同尺度的表達方式，而各國死亡率趨勢與其平均值的高度一致，也證實了國家層級資料的穩定性。值得注意的是，疫苗施打率與死亡率之間的相關係數普遍偏低，並未呈現強烈的線性關係，這暗示兩者間的關係不能僅依賴相關係數下定論，可能受限於時間延遲、疫情波段、醫療量能或人口結構等複雜變因，因此後續仍需進行更深入的數據分析。




圖 4-1、熱力圖

### 4.2 各洲的平均疫苗施打率與每百萬人死亡率長條圖

各洲平均死亡率長條圖(圖 4-2)顯示，在洲別層級的平均數據下，死亡率的高低並無法單純歸因於疫苗施打率的差異。觀察數據可以發現，疫苗施打率較高的地區並不一定對應較低的死亡率，這說明了死亡率是一個受多重因素交織影響的結果。具體而言，各洲的疫情爆發時點不同、人口年齡結構(如高齡化程度)的差異、醫療體系的承載量負

荷，以及各國防疫政策的嚴謹度與執行力，皆在死亡率的呈現上扮演了關鍵角色，使得疫苗與死亡率之間不存在簡單的線性因果關係。




圖 4-2、各洲的平均疫苗施打率與每百萬人死亡率長條圖

### 4.3 全球疫苗施打率與死亡率之月平均趨勢圖

由全球疫苗施打率與死亡率之月平均趨勢圖(圖 4-3)可知, 在全球尺度下, 疫苗施打率與死亡率隨時間呈現明顯的變化趨勢。自 2021 年初起, 疫苗施打率隨時間逐月增加, 而每百萬人死亡率則呈現整體下降的情形, 顯示兩者在長期趨勢上具有一致的變動方向。進一步比較兩項指標可發現, 疫苗施打率的提升與死亡率的下降並非同時發生, 而是存在時間上的落後關係。此現象顯示, 疫苗施打後需經過一定期間, 方能逐步反映於死亡率的變化, 符合疫苗施打後免疫效果建立的實際情形。整體而言, 疫苗施打率與死亡率在全球層級呈現負向趨勢關聯, 惟死亡率之變動仍可能同時受到疫情發展階段、病毒變異、醫療量能及各地防疫政策差異等因素影響。因此, 本節分析主要用於說明全球疫苗施打與死亡率之整體趨勢, 相關結果應審慎解讀, 並不宜直接作為疫苗施打效果之因果推論依據。




圖 4-3、全球疫苗施打率月平均趨勢圖

## 伍、實驗設計

本研究採用分類模型(**Classification Model**)作為主要分析方法, 係基於因變項之資料型態與研究目的之考量。依據研究設計, 因變項(Y)設定為疫苗接種程度, 屬於類別型變數, 用以描述各地區在疫苗接種推動上的整體分級狀態, 其結果為離散類別而非連續數值, 因此不適合以迴歸模型進行分析。

此外, 分類模型能透過混淆矩陣(Confusion Matrix)與分類報告(Classification Report)進一步評估模型在不同類別下的表現, 如 precision、recall 與 F1-score, 使研究不僅停留在

整體準確率(accuracy)，亦能更細緻地觀察模型在各類別上的判別能力，避免因資料分布不均而產生誤導性的結論。基於上述理由，本研究選擇分類模型作為分析方法，在研究目的、資料結構與結果解釋上皆具有合理性與適切性。

## 5.1 建立模型

### 1. 選擇變數

依據教授之建議，本研究重新調整自變項與因變項之設定，使模型結構與研究目的更為一致。在自變項(X)部分，選取與疫情控制與疫苗效益直接相關之指標，包含疫苗施打率(**ratio**)、每百萬人口新增死亡數(**ratio\_dead**)以及完整接種率(**ratio\_full**)，上述變數可反映各地區疫苗覆蓋情形與疫情嚴重程度，作為判斷依據具備實質意義。

在因變項(Y)部分，則設定為疫苗接種程度，屬於類別型變數，用以表示不同地區在疫苗接種推動上的整體狀態與分級結果。由於研究重點在於根據多項疫情與接種相關指標，判斷其所屬之接種程度類別，而非預測單一連續數值，因此本研究問題本質屬於分類問題。基於自變項與因變項之型態，以及研究欲達成之判別目標，採用分類模型進行分析在方法論上具有一致性與合理性。

```
# X: 模型輸入特徵
X = data[['ratio', 'ratio_dead', 'ratio_full']]

# y: 疫苗接種程度 (低 / 中 / 高)
y = pd.qcut(
    data['ratio_full'],
    q=3,
    labels=['Low', 'Medium', 'High']
)
```

圖 5-1、設定自變數和因變數之程式碼

### 2. 資料分割

在模型訓練與評估階段，本研究將資料集進行訓練集與測試集之分割，其中 **80%** 作為訓練資料、**20%** 作為測試資料(**test\_size = 0.2**)。此分割比例可在確保模型具備足夠學習樣本的同時，保留部分未參與訓練的資料用以評估模型之泛化能力，避免因僅在訓練資料上表現良好而產生過度擬合的情形。

此外，為確保實驗結果具備可重現性，本研究設定 `random_state = 42` 作為隨機種子，使每次進行資料分割時皆能得到相同的訓練集與測試集配置，利於後續模型比較與結果驗證。另考量因變項「疫苗接種程度」屬於類別型資料，且各類別之樣本數可能不均，本研究於資料分割時採用 分層抽樣(**stratified sampling**)，即設定 `stratify = y_encoded`，使訓練集與測試集中各類別之比例分布與原始資料集保持一致，以降低類別不平衡對模型評估結果所造成的偏誤。

```
from sklearn.model_selection import train_test_split

# 採用 80% 訓練集、20% 測試集（分層抽樣）
X_train, X_test, y_train, y_test = train_test_split(
    X, y_encoded,
    test_size=0.2,
    random_state=42,
    stratify=y_encoded
)

print("訓練集筆數:", len(X_train))
print("測試集筆數:", len(X_test))
```

圖 5-2、資料分割之程式碼

## 陸、模型建立與預測

### 6.1 模型訓練

本研究於模型訓練階段採用隨機森林(**Random Forest**)分類模型作為主要分析方法。隨機森林屬於集成學習(ensemble learning)方法，透過建立多棵決策樹並整合其預測結果，可有效處理資料中可能存在的非線性關係，適合應用於疫苗施打率、死亡率與完整接種率等變數之間關係複雜且難以以線性假設描述的情境。

此外，隨機森林在每棵樹的建構過程中引入隨機抽樣與隨機特徵選取機制，使模型對於資料雜訊具有較高的容忍度，並能降低單一模型過度擬合的風險，進而提升整體預測結果的穩定性。相較於單一決策樹模型，隨機森林在面對實際資料分布不均或變異較大的情況下，通常能表現出較佳的泛化能力。

在模型解釋性方面，隨機森林可計算各輸入變數之特徵重要度(**feature importance**)，有助於分析不同疫情與接種相關指標在判斷疫苗接種程度時所扮演的相對影響角色，提升研究結果在實務與政策解讀上的價值。

在模型參數設定上，本研究進行超參數設定以平衡模型表現與複雜度。其中，決策樹棵數設定為 **201** (`n_estimators = 201`)，以確保模型具備足夠的集成效果並提升預測穩定性；最大樹深設定為 **20** (`max_depth = 20`)，用以限制單棵決策樹之複雜程度，避免模型過度擬合訓練資料。上述參數設定係基於模型效能與穩定性之整體考量。

另考量各洲別(類別)在樣本數上存在不均衡情形，本研究於模型訓練時設定 `class_weight = balanced`，使模型在學習過程中能自動依各類別樣本比例調整權重，避免預測結果過度偏向樣本數較多之洲別，進而提升模型對於少數類別之判別能力與整體分類公平性。

```
from sklearn.ensemble import RandomForestClassifier

# 建立 Random Forest 分類模型 (使用奇數棵樹，避免投票平手)
rf_model = RandomForestClassifier(
    n_estimators=201,
    max_depth=20,
    class_weight="balanced",
    random_state=42
)

# 模型訓練
rf_model.fit(X_train_res, y_train_res)
```

圖 6-1、模型訓練程式碼

## 6.2 模型效能評估

在模型效能評估方面，本研究不僅以整體預測表現作為判斷依據，亦透過多種評估方式，全面檢視分類模型在不同類別下之判別能力與穩定性。首先，針對測試集之預測結果，本研究使用混淆矩陣 (**Confusion Matrix**) 進行分析，藉此觀察模型在各洲別(疫苗接種程度類別)之實際分類情形。混淆矩陣可清楚呈現各類別被正確分類與誤分類的筆數，有助於辨識模型是否在特定洲別上出現判斷偏誤，避免僅以整體準確率評估而忽略個別類別表現不佳的情況。

此外，為評估模型在不同資料切分情境下之穩定性與泛化能力，本研究進一步採用交叉驗證 (**cross-validation**) 作為輔助評估方式。透過多次重複訓練與驗證，可降低單一次資料分割所造成的偶然性影響，並檢驗模型效能是否具有一致性，確保研究結果具備可靠性與再現性。

在模型結果解讀方面，本研究亦分析隨機森林模型所計算之特徵重要度 (**feature importance**)，以了解疫苗施打率、每百萬人口新增死亡數及完整接種率等變數，在判斷疫苗接種程度時所扮演的相對影響程度。此外，透過檢視測試集中各類別之預測結果分



布，可進一步確認模型是否仍存在偏向特定樣本數較多類別的情形，作為搭配混淆矩陣解讀的重要依據。

綜合上述評估方式，本研究得以從「分類正確性」、「類別判別能力」以及「模型穩定性」等不同面向，對分類模型之效能進行完整且多層次的分析。

```
from sklearn.metrics import accuracy_score, classification_report, cor

# 預測測試集
y_pred = rf_model.predict(X_test)

# 計算準確率
accuracy = accuracy_score(y_test, y_pred)
print("測試集準確率：", accuracy)

# 分類報告
print(classification_report(y_test, y_pred, target_names=le.classes_))

# 混淆矩陣
cm = confusion_matrix(y_test, y_pred)
print("混淆矩陣：\n", cm)
```

圖 6-2、模型效能評估之程式碼

## 柒、驗證和結果

### 7.1 混淆矩陣

由混淆矩陣結果可知，縱軸代表資料之真實洲別，橫軸則為模型所預測之洲別，矩陣中各數值顯示不同洲別在實際分類與預測分類之間的對應關係。當預測結果落在矩陣對角線位置時，表示模型成功將資料判斷為正確的洲別，因此數值越集中於對角線，代表模型整體分類表現越佳。

從結果觀察可發現，歐洲洲別在對角線上的正確分類數量最高，顯示模型對該洲別之辨識能力相對穩定，推測與其樣本數較多、資料特徵較為明確有關。相較之下，大洋洲由於樣本量相對較少，在混淆矩陣中可見其部分資料易被誤判為其他洲別，顯示少數類別在分類過程中較容易受到其他洲別資料特性的影響。

整體而言，混淆矩陣中多數預測結果集中於對角線位置，僅少部分出現跨洲別誤判情形，顯示本研究所建構之分類模型在測試集上具備合理且可接受的整體分類能力，並能有效反映不同洲別間之差異。




圖 7-1、混淆矩陣

## 7.2 特徵重要度分析

本研究透過隨機森林(Random Forest)模型進行分類分析，並使用 Gini importance 作為特徵重要度的衡量指標，以評估各輸入變數在洲別分類任務中的相對貢獻程度。特徵重要度的概念在於量化每一個變數在模型建立過程中，對於降低節點不純度所做出的貢獻，數值越高代表該變數在模型判斷中扮演越關鍵的角色。分析結果顯示，模型並非依賴單一指標進行分類，而是同時綜合疫苗施打率、完整接種率以及每百萬人口新增死亡數等多項資訊進行判斷，反映出不同洲別在疫情衝擊與疫苗推進進度上，確實存在可被模型捕捉的結構性差異。此結果亦提升了模型的可解釋性，說明分類結果並非隨機產生，而是建立在具實質意義的公共衛生指標之上。






圖 7-2、隨機森林模型洲別分類預測次數分布圖

### 7.3 預測結果分布

為進一步檢視模型在多分類任務中的預測行為，本研究分析模型於測試資料上的預測結果分布情形。由預測結果分布可觀察到，模型的預測並未明顯集中於單一洲別，而是相對均勻地分布於各洲類別，顯示模型並未因樣本數差異而產生嚴重偏向。此結果說明在設定類別權重平衡 (`class_weight = balanced`) 後，模型能在不同洲別之間維持一定程度的公平性與穩定性，避免過度傾向樣本數較多的類別。整體而言，預測結果分布支持本研究所建立之模型具備合理的多分類能力，亦顯示其適合作為分析各洲疫情與疫苗接種特徵差異的工具。




圖 7-3、各洲別模型預測結果分布直方圖

#### 7.4 交叉驗證設計

為確保所建立之隨機森林模型不僅在單一資料切分下表現良好，並具備良好的穩定性與泛化能力，本研究進一步採用五折分層交叉驗證 (Stratified 5-fold Cross Validation) 進行模型評估。此方法將資料集依照洲別比例進行分層後，平均分為五個子集，並輪流以其中一折作為驗證資料，其餘四折作為訓練資料，使每一類別在訓練與驗證過程中皆能維持相近的分布結構。

交叉驗證結果顯示，各折模型的平均準確率與先前測試集評估結果相近，且準確率的標準差偏小，代表模型在不同資料切分條件下皆能維持一致的分類表現。此結果說明本研究所建立之模型並未過度依賴特定訓練資料配置，具有良好的穩定性與泛化能力，亦提升了模型應用於整體資料分析之可信度。

```

from sklearn.model_selection import StratifiedKFold
from sklearn.metrics import accuracy_score
import numpy as np

skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

fold = 1
cv_acc = []

for train_idx, val_idx in skf.split(X, y):
    print(f"Fold {fold}")
    print("  Train size:", len(train_idx))
    print("  Validation size:", len(val_idx))

    X_train_cv, X_val_cv = X.iloc[train_idx], X.iloc[val_idx]
    y_train_cv, y_val_cv = y.iloc[train_idx], y.iloc[val_idx]

    rf_model.fit(X_train_cv, y_train_cv)
    y_val_pred = rf_model.predict(X_val_cv)

    acc = accuracy_score(y_val_cv, y_val_pred)
    cv_acc.append(acc)

    print("  Validation accuracy:", round(acc, 4))
    print("-" * 30)

    fold += 1

print("CV mean accuracy:", np.mean(cv_acc))
print("CV std:", np.std(cv_acc))

```

圖 7-4、交叉驗證之程式碼

## 7.5 小結

本研究以疫苗施打率(ratio)、每百萬人口新增死亡數(ratio\_dead)及完整接種率(ratio\_full)作為輸入特徵，建構隨機森林(Random Forest)分類模型，用以預測各國所屬洲別，藉此探討不同洲別在疫苗接種進度與疫情衝擊上的整體差異。模型於測試資料上的評估結果顯示，整體分類表現具備一定準確度，且由混淆矩陣可觀察到多數預測結果集中於對角線，顯示模型能有效辨識各洲別之特徵差異，具備合理的可解釋性。

此外，透過五折分層交叉驗證進一步驗證模型之穩定性，結果顯示平均準確率與測試集評估結果相近，且標準差偏小，說明模型在不同資料切分情境下仍能維持一致的分類效能。綜合上述結果可知，本研究所建立之模型不僅具有一定的分類能力，亦具備良好的穩定性與泛化潛力，能作為分析各洲疫苗接種與死亡率差異的有效工具。

## 捌、結論

在進行跨國疫情資料分析時，首先必須重視指標標準化的重要性。由於各國人口規模差異極大，若直接比較死亡人數或疫苗施打總量等絕對數值，將無法真實反映疫情影響程度，甚至可能導致錯誤結論。因此，本研究將相關指標進行標準化處理，以「每百萬人口死亡率」取代總死亡數，並以「完整接種百分比」取代疫苗施打總劑數，藉此消除人口基數差異所造成的偏誤。此一轉換不僅提升不同國家與洲別間的可比性，也回應了資料分析中一項重要原則，即指標選擇若不恰當，將使後續分析結果失去解釋意義。

進一步分析資料特性後，本研究發現資料具有明顯的分類結構，因此建構隨機森林分類模型，以探討資料中是否存在可被辨識的規律。模型結果顯示，不同洲別在疫苗接種速度與死亡衝擊上，確實呈現出具有一致性的特徵模式，且「每百萬人口新增死亡數」為區分各洲別最具影響力的指標之一。此結果顯示，全球疫情表現並非隨機分布，而是隨著地理區域呈現群聚現象，亦成為本研究後續深入討論不同洲別防疫差異的重要依據。

然而，分析結果亦顯示，死亡率並非僅由疫苗施打率單一因素所決定。以洲別平均值觀察，歐洲洲別的疫苗接種率約為 31.7%，整體表現並不低，但其每百萬人口死亡率卻達 5.24，為各洲中最高；相較之下，非洲洲別的接種率約為 35.6%，死亡率卻僅為 1.11。此一「疫苗施打率不低，但死亡率仍偏高」的現象，顯示疫苗保護效果仍會受到多重結構性因素影響。

其中，人口老化程度為關鍵因素之一。歐洲為全球高齡化程度最高的地區之一，而高齡族群感染 COVID-19 後的死亡風險顯著高於年輕族群，即使在疫苗施打後，整體基礎死亡風險仍然偏高。此外，醫療資源承載能力亦會影響死亡率表現，當疫情於短時間內大規模爆發，即便疫苗可降低重症比例，醫療體系若面臨超載，仍可能導致死亡率上升。另一方面，不同洲別在防疫政策與面對變異株時的應對策略亦有所差異，部分地區較早放寬管制、嘗試與病毒共存，其政策時點亦反映在死亡率的波動上。最後，各國與各洲在疫情資料通報完整性上的差異，也可能影響死亡率統計結果，醫療統計體系較完善的地區，死亡案例被完整記錄的比例相對較高。

綜合上述分析可知，疫苗施打率雖為影響 COVID-19 死亡風險的重要因素之一，但並非唯一決定因素。若欲全面理解疫情資料所呈現的差異，仍須同時考量人口結構、醫療資源、防疫政策及資料品質等多重面向，方能較為完整地解釋數據背後所反映的現象。

## 玖、參考文獻

1. Ritchie, H., Mathieu, E., Rod s-Guirao, L., Appel, C., Giattino, C., Ortiz-Ospina, E., Hasell, J., Macdonald, B., Beltekian, D., & Roser, M. (2020). Coronavirus pandemic (COVID-19). *Our World in Data*. [COVID-19 Pandemic - Our World in Data](#)
2. Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. [Random Forests | Machine Learning](#)
3. Levin, A. T., Hanage, W. P., Owusu-Boaitey, N., Cochran, K. B., Walsh, S. P., & Meyerowitz-Katz, G. (2020). Assessing the age specificity of infection fatality rates for COVID-19: Systematic review, meta-analysis, and public policy implications. *European Journal of Epidemiology*, 35(12), 1123-1138. [Assessing the age specificity of infection fatality rates for COVID-19: systematic review, meta-analysis, and public policy implications | European Journal of Epidemiology](#)

4. Lawal, Y. (2021). Africa's low COVID-19 mortality rate: A paradox? *International Journal of Infectious Diseases*, 102, 118-122. [Africa's low COVID-19 mortality rate: A paradox? - ScienceDirect](#)

## 拾、問題答覆與建議

### 10.1 問答與改善

1. 變項過少，可不用做 **PCA**。

Ans. 已刪除PCA且補充處理不合理數值。(112029020蔡欣倫)

2. 應採用死亡率，而非死亡人數。

Ans. 新增死亡率，及修改視覺化分析。(112029026林昀蓁)

3. 可使用**2分法**觀察 **rate**。

Ans. 將直條圖改為2分法，觀察接種率VS死亡率間的可控度。

(112029033賴雅秀)

4. 教授：「你的州別應該是放在你自變項，因為你要調整。今天如果是亞洲，假設你的 **Y** 是疫苗施打率，或者是百萬人口的死亡率，那你就可以看到不同的州，是不是死亡率會不一樣，或者施打率會不一樣。所以不是應該 **Y** 才是你要觀察的這一個東西，那這個州只是你的操縱變因。」

Ans. 「我們做這樣的方式，並不是想要精準地預測每個國家會對到哪一個州別，而是想要觀察各個州別，在這些指標上是不是有差異性或一致性。」

(112029007孫裔晴)

教授：「以各位以前學統計學來講，你們喜歡講操縱變因。」

我今天如果不管任何一個州，我想知道死亡率或接種率是受到哪些因素影響，對不對？那如果我今天想要看亞洲，我就把這個變項給亞洲，我就知道它的死亡率或接種率是多少。那我再換成歐洲，就可以比較亞洲跟歐洲的差別。」

「所以你的 **Y** 應該是你關心的議題，州別只是用來看會不會造成結果差異。」

Ans. 依據教授建議修正 **X** 與 **Y** (112029053陳怡辰)

### 10.2 老師建議

1. 模型中的應變數(**Y**)應設定為研究者真正關心的結果變數，例如疫苗施打率或每百萬人口死亡率，而不應將洲別作為 **Y**。
2. 洲別應視為解釋變數或控制變數(操縱變因)，用來觀察不同地區是否對結果產生差異，而非作為預測目標。

3. 目前的模型設計偏向分類問題，但 研究主軸實際上更接近因果或影響因素分析，應調整模型架構以回應研究目的。
4. 若目標是比較不同洲別在死亡率或接種率上的差異，應讓模型直接反映這些結果變數，而非間接推論。
5. 對於多分類問題，應呈現各類別在每一折中的樣本數，以避免類別不平衡影響模型結果。
6. 模型訓練與測試資料的組成需清楚呈現，讓評估結果具備說服力。
7. 建議選出影響力最高的幾個特徵，並說明其對結果變數的影響方向(正向或負向)。
8. 特徵重要性結果應與視覺化分析交叉驗證，以提升解釋的完整性。
9. 當比較疫苗施打率與死亡率時，應採用成對呈現方式(例如同圖、同時間軸或同洲別)以利比較。
10. 時間序列分析中，相關變數應同步呈現，避免因分開作圖而失去分析意義。
11. 應強化模型分析與視覺化結果之間的連結，而非各自獨立解釋。
12. 機器學習模型的優勢在於可同時考量多個變數，報告中應善用此特性補足統計分析的不足。
13. 建議透過模型結果直接回應研究假設，而非僅停留在描述性或相關性層次。
14. 目前資料整理與前處理方向正確，但分析深度尚未完全發揮模型的價值。
15. 報告重點應由「描述資料」轉向「解釋結果與原因」。

## 拾壹、附錄

### 11.1 工作分配

共同工作:簡報製作

|               |                      |
|---------------|----------------------|
| 112029007 孫裔晴 | 資料前處理、實驗設計、書面報告      |
| 112029020 蔡欣倫 | 資料前處理                |
| 112029026 林昀蓁 | 資料說明、視覺化分析、結論        |
| 112029033 賴雅秀 | 資料說明、研究目的及預期結果、視覺化分析 |
| 112029053 陳怡辰 | 實驗設計、模型建立與預測         |

## 11.2 討論紀錄



圖11-2、會議參與圖

## 11.3 討論參與度

附表以 LINE 群組聊天紀錄之訊息數作為討論參與程度之輔助指標，實際分工仍依各成員負責之任務內容與完成情形進行整體評估。

| 成員  | 群組訊息數 | 討論參與情形  | 分工角色說明                          |
|-----|-------|---------|---------------------------------|
| 賴雅秀 | 86    | 討論參與度高  | 主動提出研究方向、整理與修正報告內容，負責視覺化與整體內容調整 |
| 孫裔晴 | 82    | 討論參與度高  | 統籌分工、資料前處理與程式整合，協助進度追蹤與最終彙整     |
| 林昀蓁 | 61    | 討論參與度中高 | 穩定參與討論，負責結果整理與圖表修正              |
| 蔡欣倫 | 32    | 討論參與度中  | 主要負責程式檢查與技術相關調整                 |
| 陳怡辰 | 13    | 討論參與度較低 | 協助提供資料與檔案支援                     |

表11-3、參與度附表



## 11.4 修課心得

1.112029007 孫裔晴

在本次資料探勘課程中，我擔任組長，主要負責資料前處理與實驗設計相關工作。透過這次專題實作，我對資料探勘的理解有了明顯轉變，也逐漸體會到理論與實務之間的落差。過去在學習資料分析時，往往會將重心放在模型選擇與演算法效果上，但實際接觸完整資料流程後，才發現資料品質與分析架構往往比模型本身更具決定性。

在資料前處理階段，我們花費大量時間檢查缺失值、異常值與資料尺度問題。這個過程讓我深刻體會到，若直接使用原始資料進行分析，即使模型看似精準，結果也可能因資料偏誤而失去解釋意義。例如，不同國家在人口規模上的巨大差異，使得指標若未經標準化便進行比較，將容易導致錯誤結論。這樣的經驗讓我理解，資料探勘並非單純套用工具，而是必須在分析之前對資料本身進行充分理解與判斷。

在實驗設計方面，課程也促使我重新思考分析目的與方法之間的關係。我們並非一開始就決定使用某個模型，而是先釐清資料具備的特性與研究問題，再選擇適合的分析方式。透過分類模型的實作，我逐漸理解資料探勘的價值不僅在於預測結果，更在於協助研究者發現資料中的結構性差異與潛在規律。這樣的過程也訓練我釐清分析邏輯，避免分析方向因技術選擇而偏離原本問題。


整體而言，這門資料探勘課程讓我建立了更為嚴謹的思維，也提升了我在面對複雜資料時，從問題定義、資料處理到分析設計的整體規劃能力。相較於單純學習演算法，本課程更讓我理解資料探勘作為一種思考方法的價值，對未來從事資料分析相關工作具有實質幫助。



2.112029020 蔡欣倫

經過這學期的學習，我覺得資料探勘這門課就像是統計的延伸，同樣都是在處理資料，但在比較與分析的層面上，資料探勘所考量的因素更加多元且廣泛。課堂中透過老師清楚的講解，搭配期間的小考加深理解，讓我能期中與期末報告中實際運用相關觀念。

在製作期末報告的過程中，透過實際操作資料，我也更加熟悉並理解資料處理的流程與方法。這些操作讓我不僅停





留在理論層面，而是能夠將學到的概念落實到實際案例中，看到資料背後所蘊含的價值與意義。此外，課堂上的討論與小組合作也讓我學會從不同角度思考問題，理解如何在多變的資料環境下做出合理的判斷與分析。

這門課不僅延續了過去所學的統計觀念，也讓我接觸並學習到許多新的知識，例如資料探勘中的各種演算法、模式發掘以及資料視覺化技巧。這學期的學習收穫良多，不僅透過實務操作，我也更加了解資料科學在現實生活與各行各業中的應用價值，提升了我解決問題的能力與批判性思考能力。

### 3.112029026 林昀蓁

透過這學期的資料探勘課程，讓我在這門課上有不少的收穫和心得。首先是關於資料彙整及運用的部分，在這次的期中報告中，由於我一開始使用錯誤的組別數據，導致做出來的熱力圖和樞紐分析表無法充分的解釋我們的核心概念，淪為無意義的圖表。在期末報告中我們修正了這個部分，使用經過標準化的數據，就可以修正因為人口基數不同造成差異的問題。學習過程中不免有覺得困難的地方，因為平時比較少接觸數據資料，也比較少運用excel, python等程式製作圖表，所以一開始在製作圖表上花了相當大的時間精力。透過這次的報告讓我對於這些應用程式更加熟悉，並且學會運用python製作熱力圖，也讓我能夠去由圖表解釋數據的可能現象。透過這次的報告主題，也讓我對於全球的醫療體系、政策和防疫行動更加了解與關注，也讓我了解到不能只單看數據的表現，也要根據每個國家地區的情況再去對於其數據做合理的解釋判斷。



### 4.112029033 賴雅秀

從一開始，我主要負責研究背景說明以及預期結果的撰寫。到了期中報告後，我開始主動協助修正組員的內容，針對整體邏輯與資料呈現進行調整。期末階段則負責資料的視覺化分析，將原本較為抽象的數據轉化為圖表，讓結果更容易被理解。

在這個過程中，我逐步培養了研究規劃能力，能夠更清楚掌握整體報告方向與進度。同時，也透過整合與修正組員內容的經驗，提升了對研究架構與邏輯一致性的敏感度。此外，為了完成資料分析與圖表呈現，我開始自行學習 Python 程式，強化資料處理、視覺化與問題解決的能力。透過一次次修改與除錯，我不再只是完成分配到的任務，而是能真正理解分析流程與結果意義，對整份報告也有更全面的掌握。



回顧整個歷程，我從一開始的被動執行，逐漸轉變為能主動理解與承擔責任，這是我在本次課程中最大的收穫。

### 5.112029053 陳怡辰

透過本次資料探勘課程的學習與期末專題實作，我對資料分析的整體流程有了更清楚的理解。課堂中所介紹的資料前處理、特徵選擇、模型訓練與評估方法，在實際操作 Random Forest 模型時都有具體應用。透過解讀混淆矩陣與交叉驗證結果，我學會從不同角度評估模型效能，而不只是單純關注準確率數值。整體而言，本課程讓我能將理論與實務結合，提升對資料探勘實際應用的認識。



## 11.5 程式碼

### 1. 資料載入

```
print("1. 資料載入")
file_path = 'covid_vaccination_vs_death_ratio.csv'
df = pd.read_csv(file_path)
print(f"原始資料形狀: {df.shape}")
```

### 2. 缺失值處理

```
print("\n2. 缺失值處理")
missing_rate = df.isnull().mean() * 100
df = df.loc[:, missing_rate < 50] # 移除缺失率 > 50% 欄位
num_cols = df.select_dtypes(include=[np.number]).columns
cat_cols = df.select_dtypes(include=['object']).columns
df[num_cols] = df[num_cols].fillna(df[num_cols].median())
df[cat_cols] = df[cat_cols].fillna('未知')
print(f"缺失值已處理, 目前欄位數: {df.shape[1]}")
```

### 3. 異常值移除

```
print("\n3. 移除異常值")
before = df.shape[0]
if 'New_deaths' in df.columns:
    df = df[(df['New_deaths'] >= 0) & (df['New_deaths'] < 1_000_000)]
if 'ratio' in df.columns:
    df = df[(df['ratio'] >= 0) & (df['ratio'] <= 100)]
after = df.shape[0]
print(f"移除異常值 {before - after} 筆")
```

### 4. 將國家分類到新增洲別欄位

```
# 國家 → 洲別
```

```

country_continent = {
    # Africa
    "AGO":"Africa","BEN":"Africa","BFA":"Africa","BWA":"Africa","CAF":"Africa",
    "CIV":"Africa","CMR":"Africa","COD":"Africa","COM":"Africa","CPV":"Africa",
    "DJI":"Africa","DZA":"Africa","EGY":"Africa","ERI":"Africa","ETH":"Africa",
    "GAB":"Africa","GHA":"Africa","GIN":"Africa","GMB":"Africa","GNB":"Africa",
    "GNQ":"Africa","KEN":"Africa","LBR":"Africa","LBY":"Africa","LSO":"Africa",
    "MAR":"Africa","MDG":"Africa","MLI":"Africa","MOZ":"Africa","MRT":"Africa",
    "MUS":"Africa","MWI":"Africa","NAM":"Africa","NER":"Africa","NGA":"Africa",
    "RWA":"Africa","SDN":"Africa","SEN":"Africa","SLE":"Africa","SOM":"Africa",
    "SSD":"Africa","STP":"Africa","TCD":"Africa","TGO":"Africa","TUN":"Africa",
    "TZA":"Africa","UGA":"Africa","ZAF":"Africa","ZMB":"Africa","ZWE":"Africa",
    "SYC":"Africa",

    # Asia
    "AFG":"Asia","ARM":"Asia","AZE":"Asia","BGD":"Asia","BRN":"Asia","BTN":"Asia",
    "CHN":"Asia","GEO":"Asia","IDN":"Asia","IND":"Asia","IRN":"Asia","IRQ":"Asia",
    "ISR":"Asia","JPN":"Asia","JOR":"Asia","KAZ":"Asia","KGZ":"Asia","KHM":"Asia",
    "KOR":"Asia","KWT":"Asia","LAO":"Asia","LBN":"Asia","LKA":"Asia","MDV":"Asia",
    "MMR":"Asia","MNG":"Asia","MYS":"Asia","NPL":"Asia","OMN":"Asia","PHL":"Asia",
    "PSE":"Asia","SGP":"Asia","SYR":"Asia","THA":"Asia","TJK":"Asia","TKM":"Asia",
    "TUR":"Asia","UZB":"Asia","VNM":"Asia","YEM":"Asia",

    # Europe
    "ALB":"Europe","AUT":"Europe","BEL":"Europe","BIH":"Europe","BGR":"Europe",
    "BLR":"Europe","CHE":"Europe","CYP":"Europe","CZE":"Europe","DEU":"Europe",
    "DNK":"Europe","ESP":"Europe","EST":"Europe","FIN":"Europe","FRA":"Europe",
    "GBR":"Europe","GRC":"Europe","HRV":"Europe","HUN":"Europe","IRL":"Europe",
    "ISL":"Europe","ITA":"Europe","LIE":"Europe","LTU":"Europe","LUX":"Europe",
    "LVA":"Europe","MDA":"Europe","MNE":"Europe","NLD":"Europe","NOR":"Europe",
    "POL":"Europe","PRT":"Europe","ROU":"Europe","SRB":"Europe","SVK":"Europe",
    "SVN":"Europe","SWE":"Europe","UKR":"Europe","MLT":"Europe","SMR":"Europe",
    "IMN":"Europe",

    # North America
    "CAN":"North America","CRI":"North America","CUB":"North America",
    "DMA":"North America","DOM":"North America","GTM":"North America",
    "HND":"North America","HTI":"North America","JAM":"North America",
    "KNA":"North America","MEX":"North America","PAN":"North America",
    "SLV":"North America","TTO":"North America","USA":"North America",
    "GRD":"North America","MSR":"North America",

    # South America
    "ARG":"South America","BOL":"South America","BRA":"South America",
    "CHL":"South America","COL":"South America","ECU":"South America",
    "GUY":"South America","PER":"South America","PRY":"South America",
    "SUR":"South America","URY":"South America","VEN":"South America",

    # Oceania
    "AUS":"Oceania","COK":"Oceania","FJI":"Oceania","NCL":"Oceania",
    "NZL":"Oceania","PNG":"Oceania","PYF":"Oceania","SLB":"Oceania",
    "VUT":"Oceania","WSM":"Oceania"
}

# 新增 Continent 欄位
df["Continent"] = df["iso_code"].map(country_continent)
# 檢查未分類國家
missing = df[df["Continent"].isna()]["iso_code"].unique()
if len(missing) > 0:
    print(" 以下國家未被分類:")
    print(missing)
else:
    print(" 所有國家皆成功分類")

```

## 5.新增接種率

```
print("\n4.2 建立接種率 (百分比)")
if 'people_fully_vaccinated' in df.columns and 'population' in df.columns:
    df['vaccination_rate'] = df['people_fully_vaccinated'] / df['population'] * 100
elif 'people_vaccinated' in df.columns and 'population' in df.columns:
    df['vaccination_rate'] = df['people_vaccinated'] / df['population'] * 100
elif 'total_vaccinations' in df.columns and 'population' in df.columns:
    df['vaccination_rate'] = df['total_vaccinations'] / df['population'] * 100
else:
    print(" 無法計算 vaccination_rate, 缺少欄位。")
# 限制接種率不超過 100%
if 'vaccination_rate' in df.columns:
    df.loc[df['vaccination_rate'] > 100, 'vaccination_rate'] = 100
```

## 6.新增死亡率

```
print("\n4.3 建立死亡率 (每百萬人口)")
if 'New_deaths' in df.columns and 'population' in df.columns:
    df['death_rate_per_million'] = df['New_deaths'] / df['population'] * 1_000_000
else:
    print(" 無法計算 death_rate_per_million, 缺少欄位。")
```

## 7.新增各國、各洲平均死亡率與接種率

```
print("\n5. 新增各國／各洲平均死亡率與接種率")
if 'country' in df.columns and 'vaccination_rate' in df.columns and 'death_rate_per_million' in df.columns:
    cavg = df.groupby('country')[['vaccination_rate', 'death_rate_per_million']].transform('mean')
    df['country_avg_vaccination_rate'] = cavg['vaccination_rate']
    df['country_avg_death_rate'] = cavg['death_rate_per_million']
if 'continent' in df.columns and 'vaccination_rate' in df.columns and 'death_rate_per_million' in df.columns:
    cav = df.groupby('continent')[['vaccination_rate', 'death_rate_per_million']].transform('mean')
    df['continent_avg_vaccination_rate'] = cav['vaccination_rate']
    df['continent_avg_death_rate'] = cav['death_rate_per_million']
print("各國/各洲平均欄位建立完成。")
```

## 8.處理不合理值

```
# 刪除不必要的索引欄位
if "Unnamed: 0" in df.columns:
    df = df.drop(columns=["Unnamed: 0"])
    print("已刪除欄位: Unnamed: 0")
# 刪除關鍵欄位缺失的資料
key_columns = [
    "country", "date", "population",
    "total_vaccinations", "vaccination_rate"
]
missing_before = len(df)
df = df.dropna(subset=key_columns)
missing_after = len(df)
# 刪除不合理的數值資料
# 人口必須 > 0
pop_before = len(df)
df = df[df["population"] > 0]
pop_after = len(df)
# 疫苗接種率必須介於 0 和 1
```

```

rate_before = len(df)
df = df[(df["vaccination_rate"] >= 0) & (df["vaccination_rate"] <= 1)]
rate_after = len(df)
# 疫苗累積數不可為負
vac_before = len(df)
df = df[df["total_vaccinations"] >= 0]
vac_after = len(df)
print(f" 人口不合理刪除: {pop_before - pop_after} 筆")
print(f" 接種率不合理刪除: {rate_before - rate_after} 筆")
print(f" 疫苗數不合理刪除: {vac_before - vac_after} 筆")
# 刪除重複資料
# (同一國家、同一天只留一筆)
dup_before = len(df)
df = df.drop_duplicates(subset=["country", "date"])
dup_after = len(df)
print(f" 重複資料刪除: {dup_before - dup_after} 筆")
# 6. 結果統計
before_count = len(df)
after_count = len(df)
removed_total = before_count - after_count
print("-" * 40)
print(" 清理後資料筆數 (After Cleaning):", after_count)
print(" 總共刪除筆數:", removed_total)
print("-" * 40)
# 7. 輸出清理後資料
output_file = "vaccination_rate_cleaned.csv"
df.to_csv(output_file, index=False, encoding="utf-8-sig")
print(f" 清理完成, 已輸出: {output_file}")

```