




COVID 疫苗接種 與死亡率

指導教授:鮑永誠

組別:第七組

組員:112029007 孫裔晴(組長)

112029020 蔡欣倫

112029026 林昀蓁

112029033 賴雅秀

112029053 陳怡辰

2025.01.02

目錄



資料描述



**研究議題
預期結果**



資料前處理



實驗設計、模型



視覺化分析



分工表



資料描述

背景

112029026 林昀蓁

- COVID-19 疫情最早於 2019 年底出現首例個案，隨後在全球迅速擴散。
- 根據世界衛生組織的統計，截至 2021 年 10 月 26 日，全球已有超過 **450 萬人死亡**。
- **反疫苗團體** 對公共衛生政策及疫苗推廣造成了一定阻力。

連續型資料

112029026 林昀蓁

變量名稱	變量含意	內容
date	此數據所屬日期	2020/12/19~2021/10/26
total_vaccinations	該國使用所有 COVID 疫苗數量	65~2174043000
people_vaccinated	至少接種一劑疫苗人數	64~1100842000
people_fully_vaccinated	接種完整疫苗人數	1~1022207000
New_deaths	每日新增死亡人數	-41~8786
population	2021年各國人口	1373~1445862313
ratio	疫苗施打率	0.000724363~120.3216808

類別型資料

112029026 林昀蓁

變量名稱	變量含意	內容
country	國家名	Afghanistan、Albania、Algeria、...
iso_code	每個國家的iso代碼	AFG、ALB、DZA、...



研究議題及 預期結果



研究議題

112029026 林昀蓁

探討各洲疫苗施打率與 COVID-19 死亡率之關聯分析

重點分析	假設
疫苗施打率上升是否能有效降低 COVID-19 的死亡率	疫苗施打率與死亡率呈 負相關
各洲之間的疫苗施打率差異，是否會對死亡率產生明顯影響	疫苗施打率高的洲系，其死亡率較低
疫苗施打率變化與死亡率變化的時間趨勢是否呈現反向關係	隨著時間推進，各洲死亡率將隨施打率上升而逐漸下降

預期結果

112029026 林昀蓁

根據既有研究與防疫邏輯推論：


- 疫苗施打率與死亡率應呈**明顯負相關**
- 高接種率洲別之死亡率相對較低
- 隨時間推進，隨著施打率提升，全球平均死亡率將逐漸下降



資料前處理



將資料匯入vs code



```
1 ,country,iso_code,date,total_vaccinations,people_vaccinated,people_fully_vaccinated,New_deaths,population,ratio
2 0,Afghanistan,AFG,2021-05-11,504502.0,448878.0,55624.0,12,40146987.0,1.1180863958732445
3 1,Afghanistan,AFG,2021-05-20,547901.0,470341.0,77560.0,10,40146987.0,1.1715474438965991
4 2,Afghanistan,AFG,2021-05-24,573277.0,476367.0,96910.0,10,40146987.0,1.1865572875991914
5 3,Afghanistan,AFG,2021-05-26,590454.0,479372.0,111082.0,19,40146987.0,1.1940422826749115
6 4,Afghanistan,AFG,2021-05-27,593313.0,479574.0,113739.0,14,40146987.0,1.1945454337582044
7 5,Afghanistan,AFG,2021-05-30,600152.0,480226.0,119926.0,20,40146987.0,1.1961694659676454
8 6,Afghanistan,AFG,2021-06-02,626290.0,481690.0,144600.0,34,40146987.0,1.1998160658980461
9 7,Afghanistan,AFG,2021-06-03,630305.0,481800.0,148505.0,27,40146987.0,1.2000900590622154
10 8,Afghanistan,AFG,2021-06-08,641295.0,482952.0,158343.0,64,40146987.0,1.2029595147451537
11 9,Afghanistan,AFG,2021-06-14,662003.0,484737.0,177266.0,85,40146987.0,1.20740567654554
12 10,Afghanistan,AFG,2021-06-22,765890.0,582128.0,183762.0,78,40146987.0,1.449991751560335
13 11,Afghanistan,AFG,2021-06-27,835694.0,649434.0,186260.0,56,40146987.0,1.6176406961747838
14 12,Afghanistan,AFG,2021-06-30,886854.0,699200.0,187654.0,77,40146987.0,1.7416001853389398
15 13,Afghanistan,AFG,2021-07-05,915671.0,726349.0,189322.0,84,40146987.0,1.8092241891029082
16 14,Afghanistan,AFG,2021-07-07,934463.0,735213.0,199250.0,55,40146987.0,1.8313030564410724
17 15,Afghanistan,AFG,2021-07-11,962093.0,742934.0,219159.0,86,40146987.0,1.850534885718821
18 16,Afghanistan,AFG,2021-08-20,1201286.0,770542.0,430744.0,7,40146987.0,1.9193021882314605
19 17,Albania,ALB,2021-02-02,550.0,549.0,1.0,13,2871065.0,0.019121824131463412
20 18,Albania,ALB,2021-02-09,1127.0,689.0,438.0,12,2871065.0,0.02399806343639033
21 19,Albania,ALB,2021-02-17,1701.0,1090.0,611.0,15,2871065.0,0.037965006016931
22 20,Albania,ALB,2021-02-18,3049.0,2438.0,611.0,18,2871065.0,0.08491622446722732
23 21,Albania,ALB,2021-02-22,6728.0,6073.0,655.0,13,2871065.0,0.21152429499157976
```

描述性統計

=== 描述性統計 ===

	count	mean	std	min
Unnamed: 0	21,916.000000	10,957.500000	6,326.748586	0.000000
total_vaccinations	21,916.000000	19,496,391.971071	68,350,762.004891	65.000000
people_vaccinated	21,916.000000	12,389,941.705877	45,904,897.817776	64.000000
people_fully_vaccinated	21,916.000000	7,218,532.030754	24,326,013.418777	1.000000
New_deaths	21,916.000000	102.513552	332.678592	-41.000000
population	21,916.000000	48,481,577.875935	155,711,948.421170	1,373.000000
ratio	21,916.000000	31.531167	25.668999	0.000724

	50%	75%	max
	10,957.500000	16,436.250000	21,915.000000
	2,570,544.000000	11,171,111.000000	2,174,043,000.000000
	1,674,940.500000	6,550,948.000000	1,100,842,000.000000
	814,384.500000	4,446,461.250000	1,022,207,000.000000
	9.000000	54.000000	8,786.000000
	10,157,714.000000	38,179,601.000000	1,445,862,313.000000
	26.255923	53.202646	120.321681

⚠ 發現異常值:

New_deaths有負值:-41

ratio > 100:120.321681

缺失值檢查

```
=== 各欄位缺失比例(%) ===  
Unnamed: 0          0.0  
country             0.0  
iso_code            0.0  
date                0.0  
total_vaccinations  0.0  
people_vaccinated   0.0  
people_fully_vaccinated 0.0  
New_deaths          0.0  
population           0.0  
ratio               0.0  
dtype: float64
```

確認沒有缺失值

處理異常值

=== 異常值預覽 (前10筆) ===

	country	date	New_deaths	ratio
1740	Bangladesh	2021-10-10	-6	21.673581
5577	Ecuador	2021-07-05	-8	20.560622
6695	France	2021-08-27	-6	73.793730
6704	France	2021-09-05	-41	75.041122
7332	Gibraltar	2021-04-10	0	100.833877
7333	Gibraltar	2021-04-11	0	102.466022
7334	Gibraltar	2021-04-12	0	104.113004
7335	Gibraltar	2021-04-13	0	106.311947
7336	Gibraltar	2021-04-15	0	106.326785
7337	Gibraltar	2021-04-18	0	106.537480

⚠ 發現異常值:

New_deaths < 0: 4 筆

ratio > 100: 89 筆

總共移除異常筆數: 93 筆

原來資料筆數: 21916

處理後資料筆數: **21823**

新增資料-洲別分類

各洲資料筆數：	
continent	
Africa	1946
Asia	5055
Europe	8247
North America	3149
Oceania	600
South America	2061
Unknown	765

資料集中包含 199 個國家，
總共分類成 6 個洲別。

該洲別內，所有國家在所有日期上被計算出的總資料筆數。

新增資料-接種率

由於不同國家的總人口數不同，單純看接種人數會失真，所以我們統一用：

$$\text{接種率} = \text{完整接種人數} \div \text{總人口數} \times 100 (\%)$$

這樣可以讓不同國家間的疫苗覆蓋率更具可比性。

此外，若資料出現超過 100% 的情況（例如統計重複或更新誤差），我們會將其限制在 **100%** 以維持資料合理性。

新增資料-每百萬人口死亡率

continent	vaccination_rate	death_rate_per_million
Asia	0.138550871	0.298901634
Asia	0.193190089	0.249084695
Asia	0.241387978	0.249084695
Asia	0.276688261	0.47326092
Asia	0.283306441	0.348718573
Asia	0.298717311	0.498169389
Asia	0.360176469	0.846887962
Asia	0.369903226	0.672528676
Asia	0.394408178	1.594142046

由於各國人口數差異巨大，若直接比較「新增死亡人數」會造成誤解，因此統一使用「每百萬人口死亡率」作為衡量指標，其計算方式如下：

$$\text{每百萬人口死亡率} = \text{新增死亡人數} \div \text{總人口數} \times 1,000,000$$

此指標能將死亡數量標準化，使不同人口規模的國家之間具備可比性。

另外，若資料出現不合理的極端值（如重複統計或資料缺失導致異常偏高），我們會進行合理範圍限制與清洗，以確保資料分析的可靠性。

新增資料- 各國各洲接種率及死亡率

預覽 (部分欄位)

	country	continent	vaccination_rate	country_avg_vaccination_rate
0	Afghanistan	Asia	0.138551	0.410214
1	Afghanistan	Asia	0.193190	0.410214
2	Afghanistan	Asia	0.241388	0.410214
3	Afghanistan	Asia	0.276688	0.410214
4	Afghanistan	Asia	0.283306	0.410214
5	Afghanistan	Asia	0.298717	0.410214
6	Afghanistan	Asia	0.360176	0.410214
7	Afghanistan	Asia	0.369903	0.410214
8	Afghanistan	Asia	0.394408	0.410214
9	Afghanistan	Asia	0.441542	0.410214

比較「各國之間」與「各洲之間」的防疫表現差異。讓資料不只停留在每日或城市層級，而能觀察整體趨勢。

country_avg_death_rate	continent_avg_vaccination_rate	continent_avg_death_rate
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089
43.411765	23.244464	115.610089

處理不合理的值

✦ 前 10 筆接種率不合理的資料：

	country	iso_code	date	vaccination_rate
16	Afghanistan	AFG	2021-08-20	1.072917
22	Albania	ALB	2021-05-11	6.324691
23	Albania	ALB	2021-05-12	6.545341
24	Albania	ALB	2021-05-13	6.720015
25	Albania	ALB	2021-05-14	7.131813
26	Albania	ALB	2021-05-17	7.770740
27	Albania	ALB	2021-05-18	7.967636
28	Albania	ALB	2021-05-19	8.164531
29	Albania	ALB	2021-05-20	8.277765
30	Albania	ALB	2021-05-21	8.348017

⚠ 發現疫苗接種率不合理：
必須介於 0 和 1 之間
總共移除不合理筆數：18540

原來資料筆數：21823
處理後資料筆數：3283



實驗設計、模型



一、資料讀取

```
import pandas as pd

# 1. 讀取前處理完成之資料
file_path = "step4_with_continent.csv"
data = pd.read_csv(file_path)

# 2. 檢查資料筆數與欄位
print("資料筆數:", len(data))
print("資料欄位:", data.columns.tolist())
print(data.head())
```

讀取前處理完成之 COVID-19 疫苗與死亡率資料

二、定義 X 與 Y

```
# X: 模型輸入特徵
X = data[['ratio', 'ratio_dead', 'ratio_full']]

# y: 疫苗接種程度 (低 / 中 / 高)
y = pd.qcut(
    data['ratio_full'],
    q=3,
    labels=['Low', 'Medium', 'High']
)
```

分類模型

自變項 X :

- 疫苗施打率 ratio
- 每百萬人口新增死亡數 ratio_dead
- 完整接種率 ratio_full。

因變項 Y :疫苗接種程度

X 精準預測洲別

○觀察各洲差異性與一致性

三、資料切分

```
from sklearn.model_selection import train_test_split

# 採用 80% 訓練集、20% 測試集（分層抽樣）
X_train, X_test, y_train, y_test = train_test_split(
    X, y_encoded,
    test_size=0.2,
    random_state=42,
    stratify=y_encoded
)

print("訓練集筆數:", len(X_train))
print("測試集筆數:", len(X_test))
```

test_size = 0.2

80% 作為訓練資料、20% 作為測試資料

random_state = 42

隨機種子

stratify = y_encoded

分層抽樣

四、模型訓練

```
from sklearn.ensemble import RandomForestClassifier

# 建立 Random Forest 分類模型 (使用奇數棵樹, 避免投票平手)
rf_model = RandomForestClassifier(
    n_estimators=201,
    max_depth=20,
    class_weight="balanced",
    random_state=42
)

# 模型訓練
rf_model.fit(X_train_res, y_train_res)
```

Random Forest

- 處理非線性關係
- 資料雜訊, 穩定性
- 特徵重要度

模型參數, 使用 超參數

棵數: 201

樹深: 20

調整類別權重 `class_weight = balanced`

→ 避免偏向樣本數多類別

五、模型效能評估

```
from sklearn.metrics import accuracy_score, classification_report, cor

# 預測測試集
y_pred = rf_model.predict(X_test)

# 計算準確率
accuracy = accuracy_score(y_test, y_pred)
print("測試集準確率:", accuracy)

# 分類報告
print(classification_report(y_test, y_pred, target_names=le.classes_))


# 混淆矩陣
cm = confusion_matrix(y_test, y_pred)
print("混淆矩陣:\n", cm)
```

混淆矩陣 → 觀察類別分類結果

交叉驗證 → 評估穩定性

混淆矩陣

112029053 陳怡辰



縱軸：真實洲別

橫軸：模型預測的洲別


越靠近對角線代表預測越正確

歐洲的正確數量最多

大洋洲樣本量較少—易被其他洲別影響

預測大多集中在對角線—整體分類能力合理

特徵重要度分析



本研究使用之特徵重要性指標：
Gini importance


橫軸：三個特徵
（死亡率、完整接種率、施打率）

縱軸：重要度

數值越高，分類貢獻越大

模型不只靠單一指標猜測洲別

預測結果分布



模型預測並沒有偏向某一個洲別

模型在多分類上有一定平衡性

五、交叉驗證設計

```
from sklearn.model_selection import StratifiedKFold
from sklearn.metrics import accuracy_score
import numpy as np

skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

fold = 1
cv_acc = []

for train_idx, val_idx in skf.split(X, y):
    print(f"Fold {fold}")
    print("    Train size:", len(train_idx))
    print("    Validation size:", len(val_idx))

    X_train_cv, X_val_cv = X.iloc[train_idx], X.iloc[val_idx]
    y_train_cv, y_val_cv = y.iloc[train_idx], y.iloc[val_idx]

    rf_model.fit(X_train_cv, y_train_cv)
    y_val_pred = rf_model.predict(X_val_cv)

    acc = accuracy_score(y_val_cv, y_val_pred)
    cv_acc.append(acc)

    print("    Validation accuracy:", round(acc, 4))
    print("-" * 30)

    fold += 1

print("CV mean accuracy:", np.mean(cv_acc))
print("CV std:", np.std(cv_acc))
```

為確認模型之穩定性與泛化能力，本研究進一步採用五折分層交叉驗證進行評估。結果顯示模型平均準確率與測試集結果相近，且標準差偏小，顯示模型於不同資料切分下具備穩定之分類效能。

六、結論

本研究以疫苗施打率(ratio)、每百萬人口新增死亡數(ratio_dead)及完整接種率(ratio_full)作為輸入特徵，建立 Random Forest 分類模型以預測國家所屬洲別。模型於測試集評估結果顯示具備一定分類能力，混淆矩陣亦呈現多數類別能集中於對角線，顯示模型具可解釋之分類表現。此外，五折交叉驗證結果與測試集表現相近，且標準差偏小，表示模型在不同資料切分下具有穩定性。



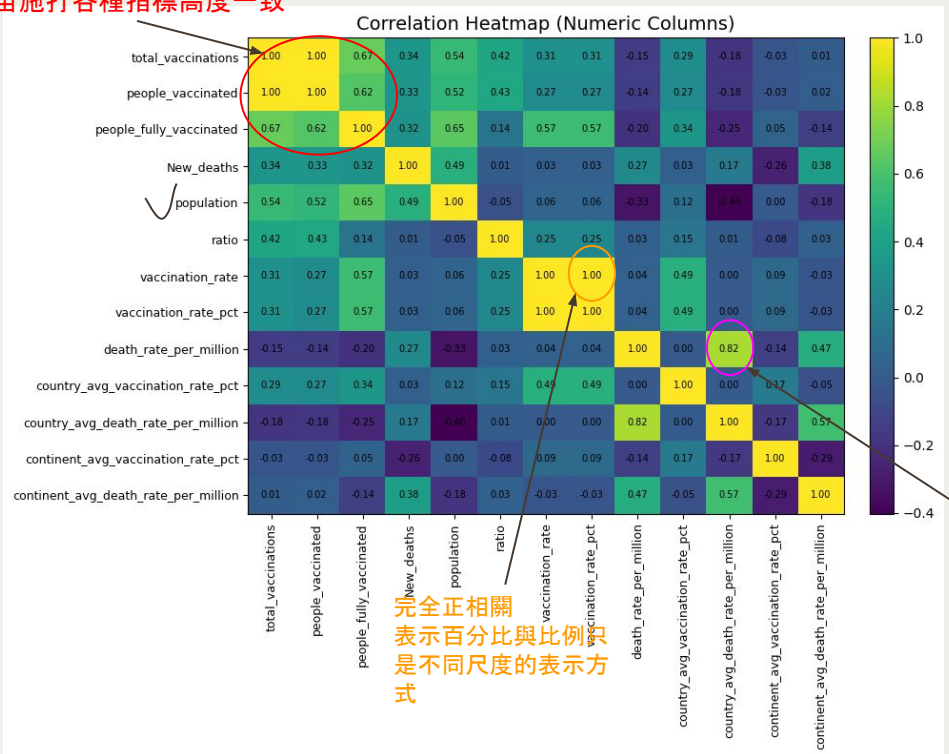
視覺化分析



數值變數間相關係數熱力圖

112029033 賴雅秀

疫苗施打各種指標高度一致



資料本身一致性高；

疫苗指標彼此高度相關；


疫苗與死亡率的關係不能只靠相關係數下結論，後續需要進一步分析。

代表單一國家的死亡率趨勢，和該國平均死亡率高度一致，資料在國家層級上是穩定的

△本圖呈現疫苗接種相關指標、死亡率與人口規模之間的相關程度。顏色越接近黃色表示正相關越高，越接近紫色表示負相關，數值介於 -1 至 1 之間。

各洲的平均疫苗施打率與每百萬人死亡率長條


疫苗施打率較高，並不一定對應較低的死亡率



在洲別平均層級下，死亡率無法單純由疫苗施打率解釋，而是同時受到疫情爆發時點、人口年齡結構、醫療體系承載量與防疫政策等因素影響。

全球疫苗施打率與死亡率月平均趨勢圖

=>全球平均疫苗施打率與死亡率的時間變化，以月為單位計算。



疫苗施打率上升的同時，死亡率呈現下降趨勢，而且這個變化並非同時發生，而是存在時間落後效果，也就是疫苗普及一段時間後，死亡率才逐漸下降。

=>>在全球尺度下，疫苗施打可能對降低死亡率具有正面影響，但這種影響需要時間累積，且仍會受到疫情變異、醫療量能與政策差異的干擾。

****疫苗施打的推進，與死亡率下降呈現一致的長期趨勢 ****



結論



指標標準化的重要性：

強調在跨國分析中，必須使用「每百萬人死亡率」與「接種百分比」來取代絕對數值，否則會因為人口基數差異而產生嚴重的分析偏誤。

數據具備分類特徵：

透過隨機森林模型證明，不同洲別在疫苗接種進度與死亡衝擊上，確實存在可以被機器學習辨識的規律特徵。根據模型分析，「每百萬人口心增死亡數」是區分各洲別最重要的指標，證明全球疫情表現並不是雜亂無章，而是群眾效應。

死亡率受多重因素影響：

雖然預期疫苗與死亡率呈負相關，但視覺化分析顯示，歐洲等高接種率地區(31.7%)的平均死亡率依然偏高(5.24)；相比之下，非洲接種率更高(35.6%)，死亡率只有1.11。說明「死亡率」不能單靠疫苗接種率解釋，還必須考慮該地區的

人口老化程度(高齡化、病毒威脅)

醫療資源(短期內疫情大規模爆發)

防疫政策及病毒株變異

數據通報誠實度等因素。

疫苗施打率只是參數，需結合上述資料才能完整解釋。



分工表



分工表

112029007 孫裔晴(組長)	資料前處理、實驗設計、書面報告
112029020 蔡欣倫	資料前處理、修改報告
112029026 林昀蓁	資料說明、視覺化分析、結論
112029033 賴雅秀	資料說明、研究目的及預期結果、 視覺化分析
112029053 陳怡辰	實驗設計、模型建立與預測

討論紀錄

